

Глава 14

Точкови оценки

14.1 Точкови оценки за средно и дисперсия

За целите на настоящата глава ще напомним някои понятия отново.

Нека имаме извадка от независими наблюдения над дадена сл.в.: $X_1, X_2, \dots, X_n \sim X \sim f(x|\theta)$, т.е. от разпределение, чиято вероятностна плътност зависи от неизвестен параметър θ . Основавайки се на нея, какво можем да заключим за параметъра на разпределението θ , или за някаква функция от него $\tau(\theta)$?

Определение 14.1 *Статистика наричаме всяка функция $W(X_1, X_2, \dots, X_n)$ от извадката. Всяка статистика е точкова оценка.*

Оценката на параметъра θ ще отбелязваме с $\hat{\theta}$.

Нека отново да дадем дефинициите на извадъчното средно и извадъчната дисперсия.

Определение 14.2 *Извадъчно средно (оценка на очакването) наричаме:*

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Определение 14.3 *Извадъчна дисперсия (оценка на дисперсията) наричаме:*

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Теорема 14.1 *Нека е дадена извадка x_1, x_2, \dots, x_n от произволно разпределение. Тогава:*

a) $\min_a \sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2, .$

b) $(n-1)s^2 = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$

Доказателство: За да докажем a) прибавяме и изваждаме \bar{x} :

$$\sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x} + \bar{x} - a)^2$$

$$\begin{aligned}
&= \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x})(\bar{x} - a) + \sum_{i=1}^n (\bar{x} - a)^2 \\
&= \sum_{i=1}^n (x_i - \bar{x})^2 + 0 + \sum_{i=1}^n (\bar{x} - a)^2.
\end{aligned}$$

Очевидно е, че този израз е минимален за $a = \bar{x}$. За да докажем b), трябва само да положим $a = 0$ в a).

Теорема 14.2 Нека е дадена извадка X_1, X_2, \dots, X_n от разпределение с очакване μ и дисперсия σ^2 . Тогава:

- a) $\mathbf{E}\bar{X} = \mu$,
- b) $\text{Var}\bar{X} = \frac{\sigma^2}{n}$,
- c) $\mathbf{E}s^2 = \sigma^2$.

Доказателство: За точка a) имаме:

$$\mathbf{E}\bar{X} = \mathbf{E}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \mathbf{E}\left(\sum_{i=1}^n X_i\right) = \frac{1}{n} n \mathbf{E}X_1 = \mu.$$

Аналогично за b):

$$\text{Var}\bar{X} = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) = \frac{1}{n^2} n \text{Var}X_1 = \frac{\sigma^2}{n}.$$

За c) ще използваме резултата от Теорема 14.1:

$$\begin{aligned}
\mathbf{E}s^2 &= \mathbf{E}\left(\frac{1}{n-1} \left[\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right]\right) = \frac{1}{n-1} (n \mathbf{E}X_1^2 - n \mathbf{E}\bar{X}^2) \\
&= \frac{1}{n-1} \left(n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right) = \sigma^2.
\end{aligned}$$

14.2 Методи за получаване на точкови оценки

14.2.1 Метод на моментите

Нека $X_1, X_2, \dots, X_n \sim f(x|\theta_1, \theta_2, \dots, \theta_k)$. Определяме всички емпирични m_i (както са дефинирани по-долу) и теоретични μ'_i моменти по следния начин:

$$\begin{aligned}
m_1 &= \frac{1}{n} \sum_{i=1}^n X_i^1, & \mu'_1 &= EX^1, \\
m_2 &= \frac{1}{n} \sum_{i=1}^n X_i^2, & \mu'_2 &= E^2, \\
&\dots & & \\
m_k &= \frac{1}{n} \sum_{i=1}^n X_i^k, & \mu'_k &= E^k.
\end{aligned}$$

Приравняваме ги за съответните степени и образуваме толкова уравнения, колкото са необходими за намиране на неизвестните параметри:

$$\begin{aligned}
m_1 &= \mu'_1(\theta_1, \theta_2, \dots, \theta_k), \\
m_2 &= \mu'_2(\theta_1, \theta_2, \dots, \theta_k), \\
&\dots
\end{aligned}$$

$$m_k = \mu'_k(\theta_1, \theta_2, \dots, \theta_k),$$

Решението на получената система спрямо $\theta_1, \theta_2, \dots, \theta_k$ е т.нар. оценка по метода на моментите.

Пример 14.1 Да се намери оценка по метода на моментите за параметрите μ и σ^2 по извадка от нормално разпределение $N(\mu, \sigma^2)$.

$$\text{Решение: } m_1 = \bar{X}, \quad \mu_1 = EX = \mu \Rightarrow \hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

14.2.2 Метод на максималното правдоподобие (ММП)

Определение 14.4 Функция на правдоподобие на извадката x_1, x_2, \dots, x_n от разпределение с плътност $f(x|\theta_1, \theta_2, \dots, \theta_k)$ наричаме:

$$L(\theta|\mathbf{x}) = L(\theta_1, \theta_2, \dots, \theta_k|x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i|\theta_1, \theta_2, \dots, \theta_k).$$

Определение 14.5 Максимално-правдоподобна оценка (МПО) наричаме стойността на параметъра θ , за която стойността на функцията на правдоподобие е максимална:

$$\hat{\theta} = \arg \max_{\theta} L(\theta|\mathbf{x}).$$

Решаването на тази задача е с методи от анализа: решаване на уравненията $\frac{\partial}{\partial \theta_i} L(\theta|\mathbf{x}) = 0$, $i = 1, 2, \dots, k$ за определяне на локални екстремуми, проверка в границите на областта, втори производни и т.н.

Пример 14.2 Да се намери оценка по ММП за параметъра μ по извадка от нормално разпределение $N(\mu, 1)$.

Решение:

$$L(\mu|\mathbf{x}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x_i - \mu)^2} = (2\pi)^{-\frac{n}{2}} e^{-\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2}$$

Вместо максимума на $\frac{d}{d\mu} L(\mu|\mathbf{x})$, може да търсим този на $\frac{d}{d\mu} \ln L(\mu|\mathbf{x})$, тъй като \ln е строго растяща функция. Тогава от:

$$\frac{d}{d\mu} \left[-\frac{n}{2} \ln(2\pi) - \frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2 \right] = 0$$

следва

$$\sum_{i=1}^n (\mu - x_i) = 0,$$

откъдето

$$\sum_{i=1}^n \mu = \sum_{i=1}^n x_i,$$

или $n\mu = \sum_{i=1}^n x_i$, откъдето $\mu = \bar{X}$.

Остава да проверим дали $\frac{d^2}{d\mu^2} L(\mu|\mathbf{x}) < 0$ и какви са границите на $L(\mu|\mathbf{x})$ в $\pm\infty$, за да довършим решението на задачата.

Окончателно $\hat{\mu} = \bar{X}$.

14.3 Свойства на точковите оценки

Определение 14.6 Средноквадратична грешка на дадена оценка W на параметра θ е функция на θ , дефинирана по следния начин: $\mathbf{E}_\theta(W - \theta)^2$.

Средноквадратичната грешка може да се разложи на сума от две компоненти - дисперсията на оценката плюс (квадрата на) нейното изместване:

$$\mathbf{E}_\theta(W - \theta)^2 = \text{Var}_\theta W + (\mathbf{E}_\theta W - \theta)^2 = \text{Var}_\theta W + (\text{Bias}_\theta W)^2.$$

Определение 14.7 Изместване ($\text{Bias}_\theta W$) на т.о. W от параметра θ наричаме разликата $\mathbf{E}_\theta W - \theta$. Ако $\text{Bias}_\theta W = 0$, то оценката е неизместена, т.е. $\mathbf{E}_\theta W = \theta$.

Пример 14.3 Нека е дадена извадка $X_1, X_2, \dots, X_n \sim N(\mu, \sigma^2)$. Разглеждаме оценките \bar{X} и s^2 . За тях от Теорема 14.2 имаме, че $\mathbf{E}\bar{X} = \mu$ и $\mathbf{E}s^2 = \sigma^2$, т.е. те са неизместени. Оттук средноквадратичната грешка и за двете оценки ще бъде равна на дисперсията им: $\mathbf{E}(\bar{X} - \mu)^2 = \text{Var}\bar{X} = \frac{\sigma^2}{n}$ и $\mathbf{E}(s^2 - \sigma^2)^2 = \text{Var}s^2 = \frac{2\sigma^4}{n-1}$ (докажете последното).

Пример 14.4 Разглеждаме оценката $\hat{\sigma}^2 = \frac{n-1}{n}s^2$. За нея $\mathbf{E}\hat{\sigma}^2 = \frac{n-1}{n}\sigma^2$ и $\text{Var}\hat{\sigma}^2 = \left(\frac{n-1}{n}\right)^2 \text{Var}s^2 = \frac{2(n-1)}{n^2}\sigma^4$. Тогава:

$$\begin{aligned} \mathbf{E}(\hat{\sigma}^2 - \sigma^2)^2 &= \frac{2(n-1)}{n^2}\sigma^4 + \left(\frac{n-1}{n}\sigma^2 - \sigma^2\right)^2 = \frac{2n-1}{n^2}\sigma^4 \\ &< \frac{2}{n-1}\sigma^4 = \mathbf{E}(s^2 - \sigma^2)^2. \end{aligned}$$

Виждаме, че неизместената оценка s^2 се оказва с по-голяма дисперсия от изместената $\hat{\sigma}^2$, а оттам и по-голяма средноквадратична грешка. Тази “размяна” между дисперсия и изместеност е една от причините за трудностите при определянето на оценка с минимална средноквадратична грешка. Изобщо класът от всички оценки е твърде широк и за да можем да определим по-добри и най-добри оценки е необходимо да го ограничим. Един възможен подход е да разгледаме класа от неизместените оценки.

Определение 14.8 Дадена оценка W^* се нарича най-добра неизместена оценка (или равномерно неизместена оценка с минимална дисперсия) за $\tau(\theta)$, ако удовлетворява $\mathbf{E}_\theta W^* = \tau(\theta)$, за $\forall \theta$ и за всяка друга оценка W , за която $\mathbf{E}_\theta W = \tau(\theta)$, имаме $\text{Var}_\theta W^* \leq \text{Var}_\theta W$, $\forall \theta$.

Възможно е да ограничим отдолу дисперсията на коя да е неизместена оценка за даден параметър. Такава граница ни дава неравенството на Рао - Крамер. Ако намерим оценка, която достига тази граница, то тя ще бъде най-добра неизместена оценка за този параметър.

Теорема 14.3 (неравенство на Рао - Крамер) Нека е дадена извадка $X_1, X_2, \dots, X_n \sim f(\mathbf{x}|\theta)$ и нека $W(\mathbf{X}) = W(X_1, X_2, \dots, X_n)$ е коя да е оценка, удовлетворяваща условията:

$$\frac{d}{d\theta} \mathbf{E}_\theta W(\mathbf{X}) = \int_{\mathcal{X}} \frac{\partial}{\partial \theta} [W(\mathbf{x}) f(\mathbf{x}|\theta)] d\mathbf{x}$$

и

$$\text{Var}_\theta(\mathbf{X}) < \infty.$$

Тогава

$$\text{Var}_\theta(W(\mathbf{X})) \geq \frac{(\frac{d}{d\theta} \mathbf{E}_\theta W(\mathbf{X}))^2}{\mathbf{E}_\theta((\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta))^2)}.$$

Доказателство: Доказателството се базира на неравенството на Коши за сл.в., т.е. факта, че ако имаме две сл.в. X и Y , то за тях е изпълнено:

$$[\text{Cov}(X, Y)]^2 \leq (\text{Var} X)(\text{Var} Y), \quad (14.3.1)$$

или по друг начин:

$$\text{Var} X \geq \frac{[\text{Cov}(X, Y)]^2}{\text{Var} Y}, \quad (14.3.2)$$

като долна граница на дисперсията на X . Ще положим в (14.3.2) $X = W(\mathbf{X})$ и $Y = \frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta)$ и ще приложим неравенството на Коши.

Да отбележим, че:

$$\begin{aligned} & \frac{d}{d\theta} \mathbf{E}_\theta W(\mathbf{X}) = \int_{\mathcal{X}} W(\mathbf{x}) \left[\frac{\partial}{\partial \theta} f(\mathbf{x}|\theta) \right] d\mathbf{x} \\ = & \mathbf{E}_\theta \left[W(\mathbf{X}) \frac{\frac{\partial}{\partial \theta} f(\mathbf{X}|\theta)}{f(\mathbf{X}|\theta)} \right] \quad \text{след като сме вмъкнали втория множител под диференциала} \\ & = \mathbf{E}_\theta \left[W(\mathbf{X}) \frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right], \end{aligned} \quad (14.3.3)$$

което е първият елемент от ковариацията на $W(\mathbf{X})$ и $\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta)$. За да я пресметнем, ни трябва произведението на двете очаквания. Но, ако в (14.3.3) положим $W(\mathbf{x}) = 1$, то получаваме, че:

$$\mathbf{E}_\theta \left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right) = \frac{d}{d\theta} \mathbf{E}_\theta [1] = 0,$$

и така за ковариацията получихме, че е равна на очакването на произведението. Оттук:

$$\text{Cov}_\theta \left(W(\mathbf{X}), \frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right) = \mathbf{E}_\theta \left[W(\mathbf{X}) \frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right] = \frac{d}{d\theta} \mathbf{E}_\theta W(\mathbf{X}).$$

Освен това, от $\mathbf{E}_\theta \left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right) = 0$ следва, че:

$$\text{Var}_\theta \left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right) = \mathbf{E}_\theta \left(\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right)^2 \right).$$

Прилагайки неравенството на Коши (14.3.1), получаваме:

$$\text{Var}_\theta(W(\mathbf{X})) \geq \frac{(\frac{d}{d\theta} \mathbf{E}_\theta W(\mathbf{X}))^2}{\mathbf{E}_\theta((\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta))^2)}.$$

Следствие: Ако $X_1, X_2, \dots, X_n \sim f(x|\theta)$ са н.е.р. сл.в., то неравенството се опростява:

$$\text{Var}_\theta(W(\mathbf{X})) \geq \frac{(\frac{d}{d\theta} \mathbf{E}_\theta W(\mathbf{X}))^2}{n \mathbf{E}_\theta((\frac{\partial}{\partial \theta} \log f(X|\theta))^2)}.$$